



## INTRODUCCIÓN

El problema de optimización el cual abordará este trabajo se centra en seleccionar un conjunto óptimo de épocas de una señal de Electroencefalografía en estado de reposo, buscando maximizar el valor promedio de las métricas de calidad mientras se minimiza el número de épocas de baja calidad. Para ello, se deben tomar decisiones sobre qué épocas incluir en el conjunto seleccionado, considerando restricciones como el número mínimo de épocas buenas en una señal y un porcentaje mínimo de épocas a seleccionar. Además, se debe garantizar que las épocas seleccionadas sean contiguas. Este problema busca encontrar el equilibrio entre la calidad de las épocas seleccionadas y la eficiencia en la selección.

## TRABAJO DE INTERÉS

### 1. Automated rejection and repair of bad trials in MEG/EEG

Este estudio presenta una solución innovadora para la determinación automática de umbrales de rechazo a través de validación cruzada (Jas et al., 2016). Se demuestra que los umbrales automáticamente seleccionados tienen un desempeño comparable a los umbrales establecidos manualmente, lo que puede resultar en un ahorro significativo de tiempo al evitar la inspección visual manual de los datos. Además, se utiliza este enfoque automatizado para identificar un umbral de rechazo específico del sensor. La metodología, planteada en este trabajo se describe a continuación:

Denotemos los datos por  $X \in R^{N \times P}$  donde N es el número de pruebas y P es el número de características. P podría ser QT, es decir, el número de sensores Q multiplicado por el número de puntos de tiempo T si se debe calcular un umbral global. Para simplificar la notación se tiene que:

$$X_i = (X_{i1}, X_{i2}, \dots, X_{iP})$$

$$\bar{x} = \frac{1}{N} \sum_{j=1}^N X_i \text{ Mediana de las pruebas}$$

$$ptp(X_i) = \max(X_i) - \min(X_i) \text{ Amplitud pico a pico de las pruebas}$$

Si estamos estimando un umbral global óptimo, entonces  $P = QT$

$$\mathcal{A} = \{ptp(X_i) | i \in train_k\}$$

$$\mathcal{G}_l = \{i \in train_k | ptp(X_i) < \tau_l\}$$

$$e_{kl} = \|\bar{X}_{g_l} - \bar{X}_{val_k}\|_{FRO}$$

Adicionalmente plantean una matriz de indicadores  $C \in \{0,1\}$

$$C_{ij} = \begin{cases} 0, & \text{if ptp}(X_{ij}) \leq \tau_*^j \\ 1, & \text{if ptp}(X_{ij}) > \tau_*^j \end{cases}$$

En general, este estudio presenta un modelo algorítmico que permite rechazar y reparar automáticamente pruebas/sensores defectuosos en función de su amplitud de pico a pico.

## 2. Source-based artifact-rejection techniques for TMS–EEG

Este estudio ofrece una perspectiva valiosa sobre la modelación de señales de electroencefalografía (EEG), incluso sin emplear un método de optimización específico para el rechazo de épocas. Se destaca la capacidad de modelar una señal EEG, incluyendo los artefactos, mediante la adición de estos últimos a la señal de interés, como se describe en la ecuación presentada en el estudio (Mutanen et al., 2022).

$$\mathbf{Y}(t) = \mathbf{LJ}(t) + \mathbf{M}_A \mathbf{S}_A(t) + \mathbf{M}_N \mathbf{S}_N(t),$$

Las señales EEG, que surgen de las corrientes postsinápticas corticales, presentan patrones espaciales relativamente difusos debido a las propiedades conductoras de la cabeza. En este contexto, se propone un modelo para estas topografías, lo que permite discernir qué señales reflejan actividad cortical genuina evocada por TMS (estimulación magnética transcraneal) y cuáles son simplemente ruido y artefactos. Este enfoque ofrece una visión significativa sobre cómo abordar la interpretación y el análisis de señales EEG.

## 3. EEG epochs with less alpha rhythm improve discrimination of mild Alzheimer's.

La mayoría de los enfoques para la selección de épocas se basan en métodos de inspección visual, donde se establece una cota superior para determinar si se rechaza o no una época. Sin embargo, en este trabajo se adopta un enfoque diferente al categorizar las grabaciones utilizando el ritmo alfa y al considerar épocas de 12 segundos de duración. Se conservan aquellas épocas cuya energía excede al menos el 30%. Aunque este estudio no emplea una estrategia específica para el rechazo de épocas, proporciona información valiosa al identificar cotas superiores para el análisis de sensibilidad. Esto permite ajustar los umbrales utilizados en la selección de épocas (Kanda et al., 2017).

## VERBALIZACIÓN Y FORMULACIÓN MATEMÁTICA

### VERBALIZACIÓN

Para:

- Maximizar el valor promedio en las métricas de calidad
- Minimizar el número de épocas de baja calidad (rechazadas)

Decidir:

- Umbral mínimo de la cantidad de épocas buenas en una señal
- Cuales épocas seleccionar

Cumpliendo:

- Las métricas de calidad que permiten evaluar las épocas
- Número o porcentaje mínimo de épocas a seleccionar
- La contigüidad de las épocas seleccionadas

### DESCRIPCIÓN DE LOS COMPONENTES

#### Conjuntos

1. Conjunto de total de épocas:  
 $E = \{1, 2, 3, \dots, n\}$
2. Conjunto de señales:  
 $S = \{s_1, s_2, s_3\}$

#### Parámetros

- $n$  : Número total de épocas
- $q_{is}$  : Métrica de calidad de la época  $i \in E, s \in S$
- $p$  : porcentaje mínimo de épocas a seleccionar
- $y$  : Número mínimo de épocas buenas en una señal (es una variable sobre la que haremos análisis "de sensibilidad")

#### Variables de Decisión

- $X_i$  = Variable binaria que indica si se selecciona la época  $i \in E$ .  $X_i = 1$ , si se selecciona, y  $X_i = 0$  de lo contrario.
- $U_i$  = Variable de decisión que indica cuál es la última época seleccionada en una serie de épocas contiguas.

### FUNCIÓN OBJETIVO

1. Maximizar

$$\sum_{i \in E} q_i X_i$$

2. Minimizar

$$\sum_{i \in E} 1 - X_i$$

**Sujeto a:**

1. Número mínimo de épocas buenas en una señal

$$\sum_{i \in E} X_i \geq y$$

2. Porcentaje mínimo de épocas a seleccionar

$$\sum_{i \in E} X_i \geq p * n$$

3. Contigüidad de las épocas seleccionadas

$$X_i \leq X_{i+1} + U_i, \forall i \in E \text{ excepto la última}$$
$$\sum_{i \in E} u_i = 1 \text{ (solo hay una última época)}$$

**Dominio de las variables de decisión:**

$$x_i \in \{0,1\}, U_i \in \{0,1\}$$

**REFERENCIAS**

- Jas, M., Engemann, D., Raimondo, F., Bekhti, Y., & Gramfort, A. (2016). Automated rejection and repair of bad trials in MEG/EEG. *PRNI 2016 - 6th International Workshop on Pattern Recognition in Neuroimaging*, 1–4. <https://doi.org/10.1109/PRNI.2016.7552336>
- Kanda, P. A. M., Oliveira, E. F., & Fraga, F. J. (2017). EEG epochs with less alpha rhythm improve discrimination of mild Alzheimer's. *Computer Methods and Programs in Biomedicine*, 138, 13–22. <https://doi.org/10.1016/J.CMPB.2016.09.023>
- Mutanen, T. P., Metsomaa, J., Makkonen, M., Varone, G., Marzetti, L., & Ilmoniemi, R. J. (2022). Source-based artifact-rejection techniques for TMS–EEG. *Journal of Neuroscience Methods*, 382, 109693. <https://doi.org/10.1016/J.JNEUMETH.2022.109693>